



POLSKO-JAPOŃSKA AKADEMIA TECHNIK KOMPUTEROWYCH

SYLABUS PRZEDMIOTU

Nazwa przedmiotu:	Wprowadzenie do machine learning
Kod przedmiotu:	IML
Kierunek / Profil:	Informatyka / praktyczny
Tryb studiów:	stacjonarny
Rok / Semestr:	3 / 5
Charakter:	obowiązkowy
Odpowiedzialny:	dr inż. Paweł Syty
Wersja z dnia:	19.02.2026

1. Godziny zajęć i punkty ECTS

Wykłady	Ćwiczenia	Laboratoria	Z prowadzącym	Praca własna	Łącznie	ECTS
30 h	30 h	—	60 h	65 h	125 h	5

2. Forma zajęć

Forma zajęć	Sposób zaliczenia
Laboratorium	Zaliczenie z oceną
Wykład	Egzamin z oceną

3. Cel dydaktyczny

Celem przedmiotu jest zaznajomienie studentów z podstawowymi zagadnieniami uczenia maszynowego (w tym elementami uczenia głębokiego), głównie z wykorzystaniem sieci neuronowych (w tym sieci splotowych), a także z metodami programowania wybranych metod oraz praktycznym wykorzystaniem gotowych narzędzi.

4. Treści programowe

1. 1. Historia i definicja uczenia maszynowego. Omówienie zastosowań uczenia maszynowego. Podział metod uczenia maszynowego. Rola danych i ich jakości w uczeniu maszynowym. Przygotowywanie danych do procesu uczenia. Wstęp do języka Python.
2. 2. Wiedza niedoskonała w uczeniu maszynowym. Metody radzenia sobie z niedoskonałością wiedzy. Wnioskowanie bayesowskie. Logika rozmyta.
3. 3. Podstawy biologiczne sztucznych sieci neuronowych. Układ nerwowy zwierząt i człowieka – podział i funkcje. Odbiór i przetwarzanie bodźców przez mózg. Neuron – budowa, systematyka. Przejawy życiowe neuronów. Pamięć. Dyskusja możliwości i ograniczeń związanych z odwzorowywaniem układów biologicznych w postaci sztucznych systemów.
4. 4. Historia i podstawy sieci neuronowych. Podstawowy model komórki nerwowej – perceptron prosty i jego właściwości. Perceptron prosty jako uogólnienie regresji liniowej. Podstawowe metody uczenia perceptronu. Ograniczenia pojedynczego perceptronu. Łączenie perceptronów w większe struktury. Podstawowa klasyfikacja architektur sztucznych sieci neuronowych. Wstępna klasyfikacja zastosowań sieci neuronowych. Cechy sztucznych sieci neuronowych predestynujące je do zastosowań we współczesnym świecie.
5. 5. Sieci jednokierunkowe jednowarstwowe. Budowa, metody uczenia, zastosowania, ograniczenia. Mapa wag. Hiperparametry. Metryki. Kodowanie danych.
6. 6. Sieci jednokierunkowe wielowarstwowe. Budowa, metody uczenia, zastosowania, ograniczenia. Więcej o metodach uczenia sieci – metoda propagacji wstecznej, metoda momentum (w tym metoda Nesterova). Omówienie wybranych optymalizatorów (SGD, RMSprop, Adam). Inicjalizacja modelu. Funkcje aktywacji.
7. 7. Zdolność uogólniania sieci neuronowej. Miary zdolności uogólniania. Twierdzenie Kołmogorowa. Zbiór uczący (treningowy), walidujący i testowy. Przeuczenie i niedouczenie sieci. Metody regularyzacji. Dobór optymalnej architektury sieci. Proces redukcji wymiaru sieci. Warstwy Dropout.
8. 8. Sieci splotowe. Budowa, metody uczenia, zastosowania, ograniczenia. Operacja splotu (konwolucja). Warstwy łączące (pooling). Filtry. Biblioteka OpenCV. Metody i architektury sieci neuronowych do rozpoznawania obrazów. Sieci typu Lenet, VGGNet. Klasyfikacja wieloetykietowa. Augmentacja danych.
9. 9. Sieci autoasocjacyjne. Transfer learning. Walidacja krzyżowa. Elementy wyjaśnialnej sztucznej inteligencji.
10. 10. Sieci rekurencyjne. Budowa, metody uczenia, zastosowania, ograniczenia. Pamięci asocjacyjne. Komórki LSTM i GRU.
11. 11. Strategie gier dwuosobowych. Algorytm MINIMAX. Funkcja heurystyczna. Przycinanie alfa-beta. Idea self-play.
12. 12. Automaty komórkowe ze szczególnym uwzględnieniem ich zastosowania w uczeniu maszynowym.
13. 13. Pozostałe metody uczenia maszynowego: k-najbliższych sąsiadów, maszyna wektorów nośnych (SVM), drzewo decyzyjne, las losowy, algorytmy ewolucyjne, liniowe modele mieszane. Metody zespołowe (ensemble).
14. 14. Elementy uczenia nienadzorowanego. Analiza skupień. Algorytm centroidów

- (k-means). Analiza szeregów czasowych. Algorytm k-shape i DTW (Dynamic Time Warping).
15. 15. Elementy języka Prolog. Zapis predykatów. Wnioskowanie wstecz i w przód.
 16. // A. lista dotychczas zaproponowanych metod dydaktycznych; można zaproponować inne.
 17. Wykład:
 18. wykład
 19. wykład konwersatoryjny (z elementami dyskusji)
 20. wykład z prezentacją multimedialną
 21. wykład z prezentacją oprogramowania
 22. warsztaty
 23. Ćwiczenia / Laboratorium/Lektorat:
 24. analiza tekstów z dyskusją
 25. metoda projektów (projekt praktyczny)
 26. praca w grupach
 27. dyskusja
 28. rozwiązywanie zadań
 29. burza mózgów
 30. mind map
 31. puzzle learning
 32. studia przypadków z bazy studiów przypadków opracowanych przez firmy MŚP lub będące efektem staży
 33. praca grupowa nad projektem z wykorzystaniem nowoczesnych technik informatycznych
 34. warsztaty
 35. // B. lista dotychczas zaproponowanych metod weryfikacji; można zaproponować inne.
 36. sprawdziany wstępne „wejściówki”
 37. kolokwium
 38. kolokwium końcowe
 39. egzamin pisemny
 40. egzamin pisemny - test wyboru
 41. egzamin pisemny - tekst z lukami
 42. egzamin pisemny z zadaniami problemowymi
 43. egzamin pisemny ze studium przypadku
 44. egzamin ustny
 45. końcowe sprawozdanie z pracy w zespole
 46. prezentacja samodzielnej pracy semestralnej
 47. prezentacja elementu zespołowej pracy semestralnej
 48. prezentacja projektu i dokumentacji
 49. prezentacja mini-projektu
 50. obrona projektu
 51. rezultaty gry strategicznej

52. ocena pracy podczas ćwiczenia
53. raport z wykonanego zadania
54. ocena sporządzonego dokumentu
55. ocena sporządzonego oprogramowania
56. wskazanie źródeł użytych materiałów
57. kwestionariusz wywiadu
58. sprawozdanie z rozmowy
59. zapisanie na ścieżkę certyfikacyjną
60. //C. ECTS sposób obliczania
61. 1 punkt ECTS przyznawany jest za 25-30 godzin pracy studenta. W obliczanie punktów ECTS włącza się:
62. liczbę godzin poszczególnych przedmiotów w danym semestrze;
63. czas, jaki student poświęcił na indywidualną naukę (w tym przygotowanie do zajęć, zbieranie materiałów czy pisanie prac zaliczeniowych);
64. czas, jaki student poświęcił na przygotowanie do egzaminu i zaliczenie danego przedmiotu;
65. liczbę godzin praktyk studenckich.

5. Efekty kształcenia

Wiedza

- Student zna i rozumie zastosowania wybranych narzędzi uczenia maszynowego
- Student wie, że jakość danych ma kluczowe znaczenie w przypadku uczenia maszynowego
- Student zna i rozumie metody przechowywania danych dla uczenia maszynowego
- Student zna i rozumie zaawansowane pojęcia z zakresu uczenia maszynowego oraz sposoby ich wykorzystania w sytuacjach praktycznych.

Umiejętności

- Student potrafi wybrać odpowiednie narzędzie do rozwiązania problemu zaistniałego w przedsiębiorstwie, a wymagającego użycia uczenia maszynowego
- Student potrafi poprawnie przygotować dane i stworzyć na ich podstawie zbiory uczące, walidujące i testowe
- Student potrafi dobrać właściwe parametry wejściowe, by zoptymalizować działanie wybranych algorytmów.
- Student potrafi przeprowadzić analizę otrzymanych wyników
- Student potrafi zastosować narzędzia uczenia maszynowego w sytuacjach praktycznych.

Kompetencje społeczne

- Student jest gotów do ciągłego podnoszenia swoich kompetencji zawodowych, osobistych i społecznych oraz zna możliwości dokształcania się przez całe życie

6. Kryteria oceny

- Ćwiczenia / Laboratorium/Lektorat:
- rozwiązywanie zadań
- studia przypadków z bazy studiów przypadków opracowanych przez firmy MŚP lub będące efektem staży
- warsztaty
- Kryteria oceny
- Ocena praktycznego zastosowania kwestii omawianych na wykładach. Studenci otrzymują zadania programistyczne do wykonania podczas zajęć (do zdobycia maks. 40 punktów, z gradacją 0.5 p.)

7. Metody dydaktyczne

Wykład, laboratoria, praca własna studenta.

8. Literatura

Podstawowa:

- Daniel T. Larose „Metody i modele eksploracji danych”, PWN 2022
- Aurélien Géron, „Uczenie maszynowe z użyciem Scikit-Learn i TensorFlow”, Helion 2020
- Robert Johansson „Matematyczny Python. Obliczenia naukowe i analiza danych z użyciem NumPy, SciPy i Matplotlib”, Helion 2021
- Sebastian Raschka, Vahid Mirjalili „Python. Machine learning i deep learning. Biblioteki scikit-learn i TensorFlow 2”, Helion 2021
- Aileen Nielsen, „Szeregi czasowe. Praktyczna analiza i predykcja z wykorzystaniem statystyki i uczenia maszynowego”, Helion 2020

Uzupełniająca:

- Joel Grus, „Data science od podstaw. Analiza danych w Pythonie”, Helion 2020
- Dokumentacja pakietów Keras i Tensorflow